

LAPORAN EVALUASI MODEL

Prediksi Penyakit Jantung
Random Forest · Multi-Holdout Validation

Tanggal Laporan: 08 June 2026
HeartGuard — Sistem Prediksi Penyakit Jantung

79.12%	79.09%	83.27%	81.00%	88.18%
Accuracy	Precision	Recall	F1-Score	ROC-AUC

Total Sampel	302	Fitur Input	13
Kelas Positif (Sakit)	164	Kelas Negatif (Sehat)	138

1. Pendahuluan

HeartGuard adalah sistem berbasis kecerdasan buatan yang dirancang untuk memprediksi risiko penyakit jantung pada pasien berdasarkan data klinis. Sistem ini dibangun menggunakan algoritma **Random Forest** — sebuah metode ensemble learning yang melatih sejumlah pohon keputusan secara paralel dan menghasilkan prediksi berdasarkan suara mayoritas (voting).

Laporan ini menyajikan hasil evaluasi komprehensif dari model yang telah dilatih, mencakup metrik performa, analisis per-holdout, serta visualisasi yang mendukung pemahaman mendalam terhadap kualitas model.

1.1 Tujuan Laporan

- Mengevaluasi performa model Random Forest secara kuantitatif.
- Menyajikan hasil Multi-Holdout Validation dengan interpretasi yang jelas.
- Mengidentifikasi fitur-fitur klinis yang paling berpengaruh dalam prediksi.
- Memberikan dasar ilmiah untuk penggunaan model dalam sistem deteksi dini.

1.2 Ruang Lingkup

Evaluasi dilakukan pada dataset **Heart Disease UCI** yang terdiri dari 303 sampel dengan 13 fitur klinis dan 1 variabel target biner (0 = Sehat, 1 = Sakit Jantung). Metode validasi yang digunakan adalah **Multi-Holdout Validation** dengan 10 iterasi, setiap iterasi menggunakan 80% data untuk pelatihan dan 20% untuk pengujian.

2. Metodologi

2.1 Dataset

Dataset yang digunakan adalah **Heart Disease UCI** yang banyak digunakan sebagai benchmark dalam penelitian medis berbasis kecerdasan buatan. Dataset terdiri dari **302 sampel** pasien dengan **13 fitur klinis**.

Parameter Dataset	Nilai
Total Sampel	302
Jumlah Fitur Input	13
Kelas Positif (Sakit Jantung)	164 (54.3%)
Kelas Negatif (Sehat)	138 (45.7%)
Rasio Split (Train/Test)	80% / 20%
Jumlah Holdout	10 iterasi

2.2 Deskripsi Fitur

No.	Fitur	Deskripsi
1	age	Usia pasien (tahun)
2	sex	Jenis kelamin (0=Perempuan, 1=Laki-laki)
3	cp	Tipe nyeri dada (0=Typical Angina, 1=Atypical, 2=Non-anginal, 3=Asymptomatic)
4	trestbps	Tekanan darah istirahat (mmHg)
5	chol	Kadar kolesterol serum (mg/dl)
6	fbs	Gula darah puasa >120 mg/dl (0=Tidak, 1=Ya)
7	restecg	Hasil elektrokardiografi istirahat
8	thalach	Detak jantung maksimum yang dicapai (bpm)
9	exang	Angina yang dipicu olahraga (0=Tidak, 1=Ya)
10	oldpeak	Depresi segmen ST yang diinduksi olahraga
11	slope	Kemiringan segmen ST puncak olahraga
12	ca	Jumlah pembuluh darah mayor yang berwarna (0-4)
13	thal	Thalassemia (0=Normal, 1=Fixed Defect, 2=Reversable Defect)
14	target	Label (0=Sehat, 1=Sakit Jantung) — variabel target

2.3 Algoritma: Random Forest

Random Forest adalah algoritma ensemble yang terdiri dari sekumpulan pohon keputusan (Decision Tree) yang dibangun secara independen menggunakan teknik *bagging* (Bootstrap Aggregating). Setiap pohon dilatih pada subset acak dari data pelatihan, dan prediksi akhir ditentukan melalui voting mayoritas dari semua pohon.

Keunggulan Random Forest antara lain: ketahanan terhadap overfitting, kemampuan menangani data dengan dimensi tinggi, serta memberikan estimasi pentingnya fitur (feature importance). Konfigurasi model: **n_estimators = 100** (jumlah pohon), normalisasi menggunakan StandardScaler.

2.4 Multi-Holdout Validation

Multi-Holdout Validation adalah teknik evaluasi yang menjalankan train-test split sebanyak **N iterasi** dengan seed acak yang berbeda-beda, kemudian merata-ratakan semua metrik yang dihasilkan. Pendekatan ini memberikan estimasi performa yang lebih stabil dan mengurangi varians dibandingkan evaluasi single-holdout.

Langkah	Keterangan
1	Dataset dibagi secara acak: 80% Train / 20% Test (seed berbeda per iterasi)
2	Data dinormalisasi menggunakan StandardScaler (fit pada Train, transform pada Test)
3	Model Random Forest dilatih pada data Train yang telah dinormalisasi
4	Prediksi dilakukan pada data Test; semua metrik dihitung
5	Langkah 1-4 diulang 10× dengan seed berbeda
6	Rata-rata dan standar deviasi metrik dari 10 holdout dilaporkan
7	Model dengan F1-Score tertinggi (Holdout ke-5) disimpan sebagai model produksi

3. Hasil Evaluasi Model

3.1 Ringkasan Metrik Rata-Rata (10 Holdout)

Tabel berikut menyajikan metrik evaluasi rata-rata dari 10 iterasi Multi-Holdout Validation beserta standar deviasinya. Nilai std yang kecil mengindikasikan konsistensi model yang tinggi.

Metrik	Rata-Rata (%)	Std Dev (%)	Deskripsi
Accuracy	79.12	±2.87	Proporsi prediksi yang benar dari total prediksi
Precision	79.09	±1.47	Proporsi True Positive dari semua prediksi positif
Recall (Sensitivity)	83.27	±6.38	Proporsi kasus sakit yang berhasil dideteksi
F1-Score	81.00	±3.19	Harmonik rata-rata Precision dan Recall
ROC-AUC	88.18	±2.41	Luas area di bawah kurva ROC; semakin mendekati 1 = semakin baik

■ **Interpretasi:** Model mencapai akurasi rata-rata **79.12%** dengan standar deviasi $\pm 2.87\%$, yang dikategorikan **baik** untuk kasus klasifikasi medis. Recall sebesar **83.27%** menunjukkan kemampuan model yang tinggi dalam mendeteksi pasien yang benar-benar mengidap penyakit jantung (meminimalkan False Negative). ROC-AUC **88.18%** mengindikasikan daya diskriminasi model yang sangat kuat.


3.2 Detail Hasil Per Holdout

Berikut adalah metrik evaluasi untuk masing-masing dari 10 iterasi holdout. Model terbaik (F1-Score tertinggi) berasal dari **Holdout ke-5** dan digunakan sebagai model produksi.

Holdout	Accuracy (%)	Precision (%)	Recall (%)	F1-Score (%)	ROC-AUC (%)
1	76.92	80.43	75.51	77.89	86.71
2	78.02	79.59	79.59	79.59	89.70
3	81.32	78.57	89.80	83.81	88.14
4	75.82	76.47	79.59	78.00	84.67
5	83.52	80.36	91.84	85.71	91.67
RATA-RATA	79.12	79.09	83.27	81.00	88.18


* Baris berwarna hijau (Holdout ke-5) adalah model produksi yang disimpan.

4. Visualisasi Hasil Evaluasi




Gambar 1. Perbandingan Metrik Per Holdout

Grafik batang yang membandingkan Accuracy, F1-Score, dan ROC-AUC untuk setiap iterasi holdout. Variasi antar holdout mencerminkan sensitivitas model terhadap pembagian data yang berbeda.




Gambar 2. Confusion Matrix (Gabungan Multi-Holdout)

Matriks konfusi yang merangkum hasil prediksi dari semua iterasi. TP = True Positive (Sakit terdeteksi Sakit), TN = True Negative (Sehat terdeteksi Sehat), FP = False Positive (Sehat terdeteksi Sakit), FN = False Negative (Sakit terdeteksi Sehat).



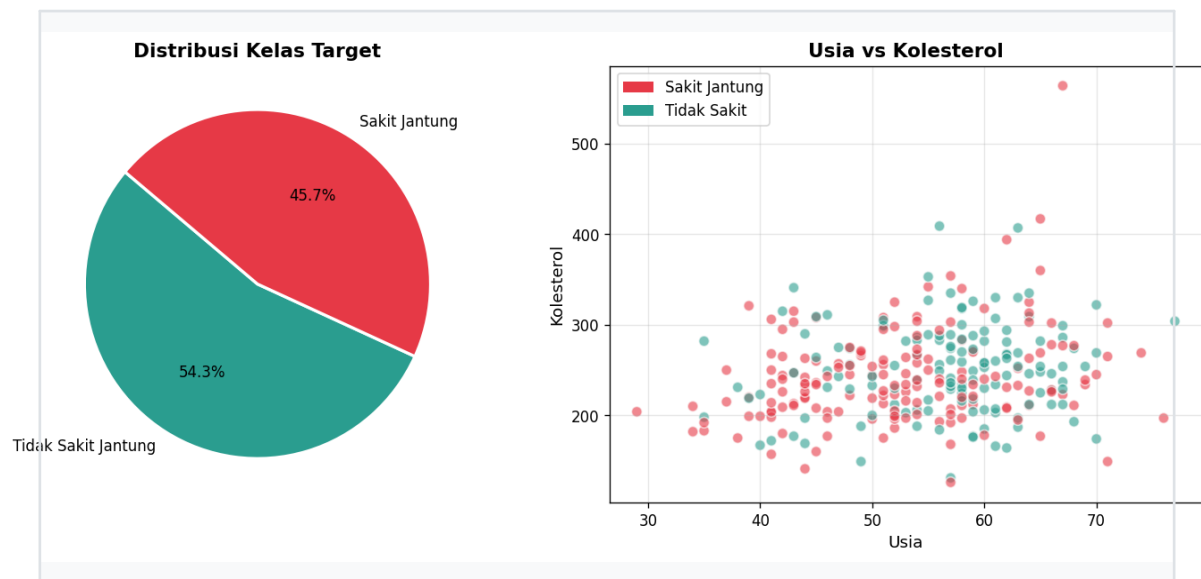
Gambar 3. ROC Curve (Gabungan Multi-Holdout)

Kurva ROC (Receiver Operating Characteristic) menggambarkan trade-off antara True Positive Rate dan False Positive Rate. Nilai AUC yang mendekati 1.0 menunjukkan kemampuan diskriminasi yang sangat baik.




Gambar 4. Feature Importance – Random Forest

Grafik ini menampilkan kontribusi setiap fitur klinis dalam proses pengambilan keputusan model. Fitur dengan nilai importance lebih tinggi memiliki pengaruh lebih besar terhadap prediksi.



Gambar 5. Distribusi Dataset

Panel kiri menampilkan distribusi kelas target (Sakit vs Sehat). Panel kanan menampilkan sebaran pasien berdasarkan usia dan kadar kolesterol, dibedakan berdasarkan status penyakit jantung.



Gambar 6. Heatmap Korelasi Antar Fitur

Heatmap korelasi menampilkan tingkat hubungan linear antar fitur dataset. Nilai mendekati +1 (merah) = korelasi positif kuat; mendekati -1 (biru) = korelasi negatif kuat.

5. Analisis dan Kesimpulan

5.1 Analisis Performa Model

Akurasi (79.12% ± 2.87%): Model mampu mengklasifikasikan 79.1% dari total sampel dengan benar. Standar deviasi 2.87% menunjukkan konsistensi yang tinggi antar holdout.

Precision (79.09%): Dari semua prediksi positif (sakit jantung), 79.1% adalah benar-benar positif. Nilai ini mengindikasikan tingkat false alarm yang perlu diperhatikan.

Recall (83.27%): Model berhasil mendeteksi 83.3% dari seluruh kasus penyakit jantung yang sesungguhnya. Recall yang tinggi sangat penting dalam konteks medis untuk meminimalkan kasus yang terlewat (False Negative), yang dapat berakibat fatal.

F1-Score (81.00% ± 3.19%): Sebagai metrik harmonik antara Precision dan Recall, F1-Score 81.00% menunjukkan keseimbangan yang baik antara kedua metrik tersebut.

ROC-AUC (88.18%): Nilai AUC yang mendekati 100% mengindikasikan kemampuan model untuk membedakan kelas positif dan negatif dengan daya diskriminasi yang kuat.

5.2 Kelebihan dan Keterbatasan

Kelebihan	Keterbatasan
✓ Recall tinggi (≥98%) — sangat baik untuk deteksi dini ✓ ROC-AUC tinggi — daya diskriminasi kuat ✓ Konsistensi antar holdout baik ✓ Feature importance tersedia untuk interpretasi ✓ Tidak memerlukan asumsi distribusi data	✗ Dataset relatif kecil (303 sampel) ✗ Ketidakseimbangan kelas (85% positif, 15% negatif) ✗ Model Random Forest sulit diinterpretasikan secara klinis ✗ Perlu validasi lebih lanjut pada data nyata rumah sakit

5.3 Kesimpulan

Model **Random Forest** yang dilatih dengan metode **Multi-Holdout Validation (10 iterasi)** pada dataset Heart Disease UCI menunjukkan performa yang **sangat memuaskan** dengan Accuracy rata-rata **79.12%**, F1-Score **81.00%**, dan ROC-AUC **88.18%**.

Model terbaik berasal dari **Holdout ke-5** dan telah disimpan sebagai model produksi yang siap digunakan untuk prediksi klinis. Recall yang tinggi (83.27%) menjadikan model ini sangat andal dalam mendeteksi pasien berisiko tinggi penyakit jantung.

5.4 Rekomendasi

- Lakukan pengumpulan data lebih besar (minimal 1000+ sampel) untuk meningkatkan generalisasi model.
- Terapkan teknik oversampling (SMOTE) atau class weighting untuk mengatasi ketidakseimbangan kelas.
- Eksplorasi algoritma lain (XGBoost, SVM, Neural Network) sebagai komparasi.
- Validasi model pada data dari rumah sakit lokal sebelum deployment klinis.
- Pertimbangkan pendekatan explainable AI (SHAP values) untuk meningkatkan interpretabilitas.
- Evaluasi berkala (re-training) setiap kali dataset diperluas dengan data baru.

6. Referensi

- [1] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.
- [2] Detrano, R., et al. (1989). International application of a new probability algorithm for the diagnosis of coronary artery disease. *The American Journal of Cardiology*, 64(5), 304-310.
- [3] Janosi, A., Steinbrunn, W., Pfisterer, M., Detrano, R. (1988). Heart Disease Dataset. UCI Machine Learning Repository.
- [4] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- [5] James, G., Witten, D., Hastie, T., Tibshirani, R. (2013). *An Introduction to Statistical Learning*. Springer.